Previsão de eventos de manutenção não programados em uma frota *Boeing 737NG* com redes neurais artificiais

Igor Gonçalves Tomaz da Silva[1]; Marcos dos Santos[2]

[1] Instituto Federal de Ciência e Tecnologia de São Paulo. Tecnólogo de Automação Industrial. Guarulhos, SP, Brasil
[2] Pecege. Prof. Dr. Marcos Santos. Instituto Militar de Engenharia (IME), Rio de Janeiro, RJ, Brasil;
*autor correspondente: igor_goncalvestomaz@hotmail.com

Previsão de eventos de manutenção não programados em uma frota Boeing 737NG com redes neurais artificiais (TCC)

Sumário Executivo

O estudo abordou o desafio do planejamento de manutenção em companhias aéreas, focando na previsão de Horas-Homem [HH] para itens não programados em aeronaves Boeing 737NG. Utilizando Deep Learning e Redes Neurais Artificiais [RNAs], o trabalho propôs um modelo preditivo com base em dados históricos de HH e informações de utilização das aeronaves entre 2015 e 2023. Foram coletados e integrados dados de manutenção não programada e utilização das aeronaves, posteriormente padronizados através do MinMaxScaler. O modelo de RNA adotado foi um Multi-Layer Perceptron [MLP] com quatro camadas, treinado usando o otimizador Adam e a função de perda MSE. A avaliação dos modelos resultou em métricas promissoras para o Modelo_1, onde foi desconsiderado o atributo “idade da frota”, indicando sua eficácia na previsão de HH.

Palavras-chave: redes neurais artificiais; regressão; horas-homem; manutenção de linha; itens não programados.

Predicting unscheduled maintenance events on a Boeing 737NG fleet with artificial neural networks

Abstract

The study addressed the challenge of maintenance planning in airlines, focusing on predicting Man-Hours [MH] for unplanned items in Boeing 737NG aircrafts. Using Deep Learning and Artificial Neural Networks [ANNs], the research proposed a predictive model based on historical MH data and aircraft utilization information from 2015 to 2023. Data from unplanned maintenance and aircraft utilization were collected and integrated, subsequently standardized using MinMaxScaler. The adopted ANN model was a Multi-Layer Perceptron (MLP) with four layers, trained using the Adam optimizer and MSE loss function. Evaluation of the models resulted in promising metrics for Model_1, where the "fleet_age" attribute was disregarded, indicating its effectiveness in predicting MH.

Keywords: artificial neural networks, regression, man-hour predict, line maintenance, unscheduled items

Introdução

O planejamento de manutenção é um desafio essencial no nível operacional nos diferentes tipos de indústrias. As tarefas de manutenção programadas e eventos não programados devem ser realizados de maneira eficiente, para aumentar o tempo de atividade dos equipamentos e a disponibilidade dos ativos (Li Yang et al., 2019). Neste contexto, a alocação eficiente de mão de obra torna-se fundamental para garantir o sucesso na execução dessas tarefas, seja elas, tarefas de manutenções preventivas ou corretivas.

Na indústria da aviação, o planejamento da manutenção é especialmente desafiador, pois envolve equipamentos robustos e complexos, envolvendo mão de obra que precisa ser altamente capacitada em diversas especialidades. Uma gestão inadequada na quantidade de mão de obra, por exemplo, pode resultar em maiores períodos de uma aeronave fora de serviço, o que leva a longos atrasos e cancelamentos de voos.

Para tratar as tarefas preventivas e não programadas de manutenção de forma eficiente, a gestão da capacidade de Horas-homem [HH] é um aspecto fundamental nesse processo. A capacidade de HH refere-se à quantidade de trabalho que um indivíduo ou equipe pode realizar dentro de um período específico. Ao monitorar e planejar a capacidade de HH de forma adequada, as empresas podem evitar sobrecarregar os técnicos e garantir que haja recursos suficientes para atender às demandas de manutenção, tanto programadas quanto não programadas (Smith e Johnson, 2018).

No que se refere a manutenção da frota de aviões operacionais, ou seja, aviões que estão aeronavegáveis e operando diariamente, os itens de manutenção realizados durante a operação de uma empresa aérea são denominados "Manutenção de Linha", esta manutenção abrange a execução de atividades de baixa complexidade (baixo HH) em uma aeronave imediatamente antes de um voo programado ou em um período de menor demanda de voos (Shaukat, 2020). Dentro da manutenção de linha, podem-se ter itens programados ou não programados. Um item programado é determinado com base em horas de voo, ciclos de voo e dias corridos, conforme estabelecido pelo Programa de Manutenção da aeronave, e em manuais do fornecedor dos componentes. Enquanto um item não programado refere-se à manutenção inesperada que pode ocorrer a qualquer momento enquanto a aeronave estiver sendo operada (Albakkous e Pagone, 2021).

De acordo com Banks e Carson (2001), a natureza imprevisível e a urgência desses eventos exigem uma abordagem cuidadosa e adaptável para a gestão de recursos humanos. A falta de previsibilidade desses eventos torna difícil determinar antecipadamente a quantidade de mão de obra necessária, o que pode levar a sub ou super alocação de pessoal. Isso não apenas aumenta os custos operacionais, mas também pode comprometer a eficiência e a segurança das operações de manutenção.

Para contornar a dificuldade em prever a mão de obra necessária para cobrir os itens não programados em uma companhia de aviação comercial, composta por uma frota unicamente de Boeing 737NG, propõe-se a utilização de Deep Learning, mais especificamente de Redes Neurais Artificiais [RNAs]. As RNAs, com sua capacidade de aprendizado profundo e análise de padrões complexos, têm mostrado eficácia em previsões de diversas naturezas, incluindo previsões de demanda e recursos humanos (Goodfellow, Bengio, e Courville, 2016).

Visando o tratamento dos dados e a elaboração do modelo, será utilizado o Python, com o auxílio das bibliotecas Pandas e Numpy para manipulação e cálculos de dataframes, Seaborn e Matplotlib para a visualização de dados em forma de gráficos, TensorFlow 2.x para desenvolvimento e treinamento do modelo preditivo de redes neurais. Este modelo utilizará

um conjunto de dados históricos de HH de todos os eventos não programados e informações sobre a utilização das aeronaves em horas e ciclos no período entre 2015 e 2023.

Esta abordagem permitirá uma análise mais precisa e adaptável das demandas de mão de obra, possibilitando uma melhor gestão dos recursos humanos no médio e longo prazo, dadas as circunstâncias burocráticas e morosas para contratação de mão de obra especializada.

Materiais e Métodos

O desenvolvimento deste trabalho envolve a aplicação de técnicas de Deep Learning para a previsão de Horas-Homem (HH) totais de itens não programados, considerando um cenário em uma companhia de aviação comercial no território brasileiro, dentro de uma frota de aviões no modelo 737NG, projetado e fabricado pela empresa Boeing.

Para a realização do estudo, foram utilizadas duas fontes de dados provenientes de uma companhia aérea atuante no mercado de aviação comercial brasileiro: uma contendo o histórico de itens não programados de manutenção de linha e horas-homem (HH), e outra compreendendo informações sobre a utilização dos aviões em horas e ciclos, ambas as bases de dados, abrangendo o período de 2015 a 2023.

Coleta, Ajuste e Integração dos Dados

Os conjuntos de dados utilizados foram "itens não programados" [INP] e "utilização das aeronaves" [UDA], ambos obtidos por meio do software de gestão de manutenção de uma companhia aérea de aviação civil brasileira. Na preparação e manipulação desses conjuntos, foram empregadas técnicas de Data Wrangling, que incluíram formatação, organização, correção, padronização e ajuste dos dados (Furche, 2016).

No primeiro conjunto de dados, INP, os campos são compostos da seguinte forma: date (data de execução da tarefa de manutenção não programada), acft (Aeronave contendo o “item não programado”), HH (HH de fato utilizado na execução do reparo/troca do “item não programado”, em formato de horas). Registros com valores de ‘HH’ superiores a 24 horas foram excluídos. Valores zerados ou nulos em ‘HH’ foram substituídos pela média aritmética desse campo. Para facilitar os cálculos e a implementação do modelo, o campo “HH” foi convertido para horas decimais. Os registros foram então agrupados por “date” e “acft”, com a soma dos valores do campo “HH”.

No segundo conjunto de dados, UDA, os campos são dispostos como: “date”, “acft”, “ciclos” (quantidade de voos operados no dia), “horas” (quantidade de horas operadas no dia),

“idade” (idade da aeronave em horas voadas totais). Assim como na base de "itens não programados", os campos em horas foram convertidos para horas decimais e o conjunto foi agrupado por “data” e “acft”, somando os valores da coluna “horas” e os valores da coluna ‘idade’.

Para integrar as duas bases de dados, foi criada uma coluna em comum, denominada "key id", resultante da concatenação entre os campos “date” e “acft”. Utilizando o recurso "left join" do pacote pandas, a tabela UDA foi considerada a base da esquerda e a tabela INP, a base da direita. Dessa forma, no dataset final, apenas os aviões operacionais foram considerados, ou seja, aqueles presentes na base UDA. Registros da base INP que não constavam na base de utilização foram, portanto, desconsiderados.

Pensando em aprimorar o desempenho do modelo, foi incluída uma coluna representando a soma da utilização mensal.

Por fim, para melhor generalização dos dados, o campo “acft” foi removido da base final e o conjunto foi agrupado novamente pelo campo “date”, em intervalos de 7 dias, onde todos os valores numéricos foram somados.

A manipulação e os ajustes realizados nas etapas anteriores foram fundamentais para a criação do dataset final, que será efetivamente utilizado na elaboração do modelo de RNA. Os campos considerados incluíram: date, acft (representando a soma de aviões operacionais no intervalo de 7 dias), horas (total de horas decimais voadas por toda a frota operacional no período de 7 dias), ciclos (total de ciclos voados por toda a frota operacional no período de 7 dias), horas_mês (total de horas decimais voadas por toda a frota operacional no período de 30 dias), idade_frota (somatória da idade dos aviões em horas decimais, de toda a frota operacional, no intervalo de 7 dias) e HH (variável de saída target, total de HH de todos os itens não programados e aviões operacionais no período de 7 dias), a Tabela 1, apresenta um exemplo, com apenas uma linha de registro, da estrutura do dataset.

Tabela 1. Linha do dataset final

Acft	Horas	Ciclos	Horas_mês	Idade_frota	HH
414	4491,00	2831,00	19548,00	7.025.606,00	1236,00

Fonte: Dados originais da pesquisa.

Normalização dos dados

Com o dataset final definido, é notável a variedade de parâmetros de entrada com diferentes dimensões numéricas, como por exemplo, a diferença significativa no tamanho do número da frota operacional (acft), e a idade da frota no presente estudo. Segundo o Zhu et al. (2019) para neutralizar as disparidades dimensionais entre os parâmetros, é crucial realizar

a padronização dos dados. Este processo garante que os parâmetros sejam comparáveis, facilitando assim a análise e integração de dados multidimensionais. Dentre eles, o mais comum é o processamento de normalização de dados. O objetivo da normalização é limitar os dados pré-processados a um determinado intervalo, para eliminar os efeitos adversos causados por dados de amostras singulares (Zhong et al., 2024). Neste trabalho, o método utilizado para esse fim é o MinMaxScaler, proveniente da biblioteca do sklearn, é usado para padronizar os registros, para isso, o dataset final foi dividido em dois, onde as variáveis de entrada (acft, horas, ciclos, horas_mês e idade_frota) passaram a compor o conjunto "X" e variável alvo o conjunto "y". A padronização é feita em cada um dos conjuntos separadamente, de modo que registros fique no intervalo entre zero e um, da seguinte forma:

$$X_{std} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Onde X_{min} é o valor mínimo do conjunto de dados X, e X_{max} é o valor máximo (Sadoune et al., 2023). Como exemplo, a Tabela 2, traz uma linha de registros do dataset final ao serem padronizados com o método MinMaxScaler:

Tabela 2. Linha do dataset final com os registros padronizados

Acft	Horas	Ciclos	Horas_mês	Idade_frota	HH
0.60992908	0.53435744	0.53419093	0.52639825	0.89974507	0.69959388

Fonte: Dados originais da pesquisa.

Redes Neurais Artificiais

O modelo RNA empregado neste estudo, foi um algoritmo de aprendizagem para reconhecer padrões realizando previsões com base em dados fornecidos. A construção de redes neurais artificiais [RNA] tem inspiração nos neurônios biológicos e nos sistemas nervosos. Pode-se dizer que as redes neurais artificiais são sistemas computacionais que imitam as habilidades do sistema nervoso biológico, usando um grande número de neurônios artificiais interconectados (Barreto, 2002). A Figura 1, demonstra o exemplo de um perceptron, ou seja, uma rede neural com apenas uma camada, onde X_i são as entradas, w_i os pesos, e por último a função de ativação.

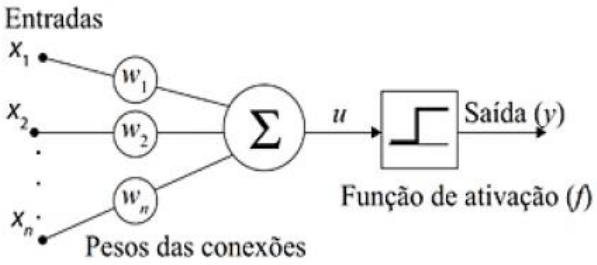


Figura 1. Estrutura de uma rede neural com uma camada
Fonte: Barreto, 2002.

As redes neurais artificiais profundas são compostas da seguinte estrutura: uma camada de entrada; uma ou mais camadas ocultas, também conhecidas como “camadas escondidas”; uma camada de saída. Pode-se considerar que cada camada nessa estrutura contém um número especificado de neurônios e uma função de ativação, que variam de acordo com o objetivo da RNA (Ferreira et al., 2011). Os neurônios em um modelo de aprendizado profundo podem formar conexões com mais de um neurônio na camada anterior. Cada conexão tem um peso que influencia a posição do neurônio anterior na rede neural geral.

A configuração arquitetônica de uma RNA multicamada é apresentada na Figura 2, onde x_i e o_i são os vetores de entrada e saída, h_i e g_i são as funções de ativação, w_i e b_i são os vetores de peso e polarização entre diferentes camadas (Zhong et al., 2024).

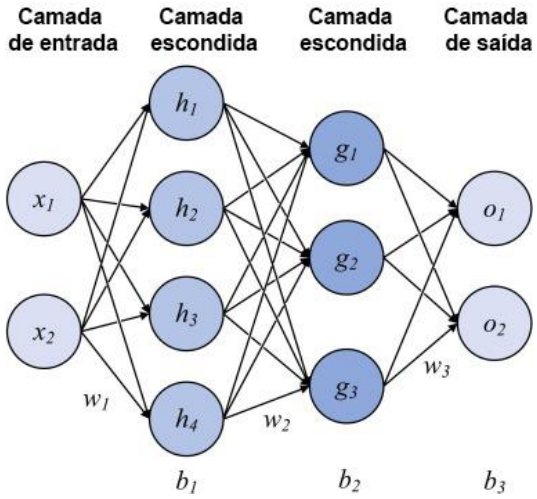


Figura 2. Estrutura de uma rede neural
Fonte: Zhong et al. (2024)
Nota: *a imagem foi traduzida do inglês para o português pelo Autor

Uma “função de ativação” em redes neurais é uma função matemática que determina a saída de um neurônio. Ela introduz não-linearidade nas redes, permitindo que as redes neurais aprendam e modelem relações complexas nos dados. Existem várias funções de

ativação comumente usadas, como a sigmóide, tanh e ReLU, cada uma com suas características e aplicações específicas (Goodfellow et al., 2016).

Para o modelo deste estudo, será utilizada a função de ativação ReLU, devido à sua simplicidade e eficácia na superação do problema de desvanecimento do gradiente, comum em redes neurais profundas. Ela é definida como:

$$f(x) = \max(0, x)$$

O que significa que ela retorna zero para todos os valores negativos de entrada e mantém os valores positivos de entrada inalterados (Hinton, 2010).

Neste estudo, o treinamento de redes neurais baseado na otimização de hiperparâmetros. Os Hiperparâmetros são parâmetros que controlam o processo de treinamento, determinam o desempenho do modelo e melhoram a reprodutibilidade com base no algoritmo de aprendizagem e nos resultados experimentais.

Métricas

Para avaliar o modelo, é necessário utilizar métricas para medir o desempenho e a precisão da saída. Para o presente trabalho, foram consideradas algumas das principais métricas: [RMSE], [MSE], R^2 e R^2 ajustado.

O [RMSE] fornece uma medida da magnitude média dos erros entre as previsões e os valores reais, sendo uma medida popular de erro em modelos de regressão. O RMSE é calculado como a raiz quadrada da média dos quadrados das diferenças entre os valores previstos e os valores reais (Hyndman e Athanasopoulos, 2018).

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Onde n é o número de amostras, y_i é o valor observado para a amostra, $\hat{y}_i$ é o valor previsto pelo modelo.

O MSE é uma métrica comumente usada para avaliar a precisão de um modelo de regressão. Ele calcula a média dos quadrados das diferenças entre os valores previstos e os valores reais. O MSE é uma função de erro contínua que fornece uma medida quantitativa da magnitude dos erros entre as previsões e os valores reais (Bishop, 1995).

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Em que n é o número total de observações, y_i é o valor observado para a amostra, $\hat{y}_i$ é o valor previsto pelo modelo.

O R^2, ou coeficiente de determinação, é uma métrica estatística que fornece uma medida da proporção da variância nos valores dependentes que, é previsível a partir dos valores independentes em um modelo de regressão. Seu valor varia de 0 a 1 e indica a

quantidade de variabilidade explicada pelo modelo em relação à variação total dos dados (Montgomery et al., 2012).

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

Sendo que, n é o número de registros, y_i é o valor equivalente a amostra, $\hat{y}_i$ é o valor previsto pelo modelo e $\bar{y}$ é a média dos valores observados.

O R^2 ajustado é uma versão corrigida do R^2 que leva em consideração o número de variáveis independentes no modelo. Ele penaliza a inclusão de variáveis irrelevantes no conjunto de dados, fornecendo uma medida mais realista da qualidade do ajuste do modelo. O R^2 ajustado é especialmente útil em modelos de regressão múltipla para comparar modelos com diferentes conjuntos de variáveis independentes (Pena e Slate, 2006).

$$R^2_{\text{ajustado}} = 1 - \frac{(1 - R^2) \times (n - 1)}{n - p - 1}$$

Onde R2 é o coeficiente de determinação, n é o número total de observações e p é o número de variáveis independentes no modelo.

Python

Considerando o alto volume de dados, à possibilidade de automatização e pela facilidade para implementação de modelos complexos de machine learning, utilizou-se a linguagem de programação Python na versão v 3.11.7. Para o tratamento e visualização dos dados aderiu-se as bibliotecas gratuitas Pandas, Numpy, Matplotlib e Seaborn. Visando a criação do modelo, foram utilizadas as bibliotecas Sklearn e TensorFlow.

A sintaxe do Python é clara e legível, o que facilita a compreensão e manutenção do código. Essa linguagem suporta diversos paradigmas de programação, abrangendo desde programação imperativa e funcional até programação orientada a objetos (Mahammadodilovich, 2023).

Treinamento do modelo

Para avaliar adequadamente a precisão de um sistema de aprendizagem profunda em dados futuros não observados, é fundamental aplicar o conceito de treinamento, validação e teste. Isso requer a divisão do conjunto de dados completo em três conjuntos distintos: o conjunto de treinamento é utilizado para identificar padrões nos dados que se correlacionam com os resultados desejados; o conjunto de validação avalia se o modelo está bem calibrado após identificar esses padrões, permitindo ajustes para otimizar o desempenho; e o conjunto

de teste proporciona uma avaliação imparcial da eficácia do modelo, evitando vieses no processo de design (Eelbode et al., 2021). Neste estudo, o conjunto de dados foi dividido em 60% para treinamento, 20% para teste e 20% para validação, utilizando a biblioteca sklearn para auxiliar nessa divisão.

A abordagem adotada para a criação e implementação do modelo supervisionado de redes neurais sequenciais, foi através da utilização da biblioteca TensorFlow 2.*x* no Python, se trata de uma biblioteca gratuita, incluindo otimizadores avançados, camadas personalizáveis, funções de ativação, métricas de avaliação e APIs simplificadas, como Keras, que facilitam a construção e treinamento de redes neurais. Além de ter uma integração fácil com bibliotecas de análise de dados do Python, como Pandas e scikit-learn, também torna o TensorFlow uma escolha ideal para trabalhar em conjunto com etapas de pré-processamento e análise exploratória de dados, enriquecendo ainda mais o processo de modelagem. As RNAs utilizadas neste trabalho foram do tipo "Multi-Layer Perceptron" [MLP] com 4 camadas, uma de entrada, duas escondidas e uma de saída. A função de ativação ReLu foi utilizada nas 3 primeiras camadas, e a função de ativação Linear foi aplicada a camada de saída.

O treinamento do modelo é realizado por atualização iterativa de pesos com base na minimização do erro quadrático médio. Na camada de saída, o sinal de erro é a diferença entre os valores desejados e os valores de saída. Em seguida, o sinal de erro é realimentado através do algoritmo de descida mais íngreme para as camadas inferiores para atualizar os pesos da rede. Os pesos da rede são ajustados pelo algoritmo de forma que o erro diminua ao longo da direção de descida.

Para acelerar o processo de aprendizagem e melhorar a convergência do modelo, optou-se pelo otimizador Adam. Este é um método de otimização baseado na descida gradiente estocástica, conhecido por exigir pouca memória, ser de implementação simples e amplamente utilizado em problemas que envolvem grandes volumes de dados e parâmetros. O otimizador ajusta as taxas de aprendizagem adaptativas para diferentes parâmetros, considerando momentos de primeira e segunda ordem (Kingma and Ba, 2017). O Adam é eficiente em termos computacionais e demanda menos memória de armazenamento em comparação com outros otimizadores (Bhandage et al., 2023).

Resultados e Discussão

A fim de gerar o melhor resultado frente às opções de variáveis independentes, os dados utilizados como parâmetros de entrada do dataset (acft, horas, ciclos, horas_mês, idade_frota) foram analisados, com o objetivo de compreender o nível de correlação com a variável de saída (HH). Utilizou-se dois tipos diferentes de visualização para comparar a correspondência dos dados: primeiro, foi gerada a "matriz de correlação", conforme a Figura 3; em seguida, gráficos de dispersão foram utilizados para relacionar as variáveis independentes com a variável target, como apresentado na Figura 4.

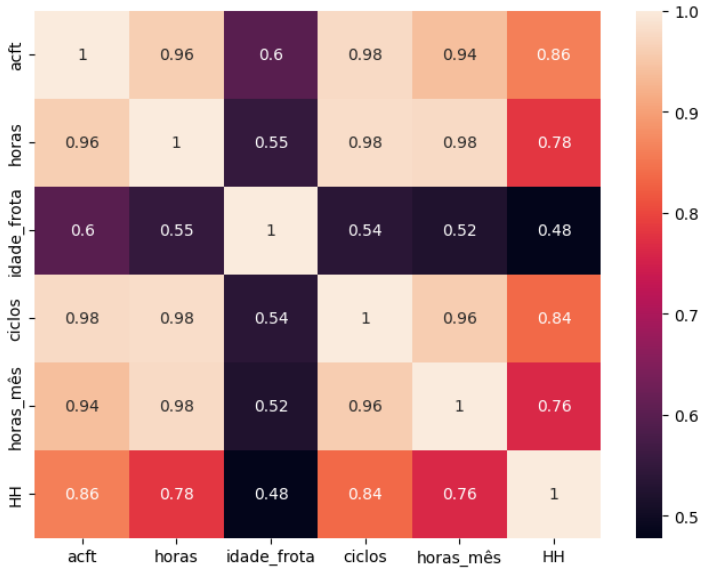


Figura 3. Representação dos dados através de uma matriz de correlação
Fonte: Resultados originais da pesquisa

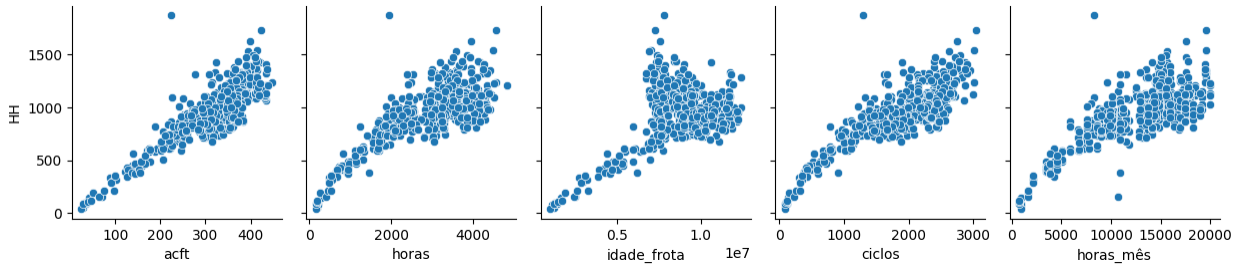


Figura 4. Relação entre as variáveis de entrada e a variável de saída individualmente
Fonte: Resultados originais da pesquisa

Observou-se que a variável de entrada "acft", que representa a quantidade de aviões operacionais, apresentou uma maior correlação com a variável de saída HH. Por outro lado, a variável "idade_frota" mostrou uma correlação abaixo do esperado, considerada fraca frente as demais variáveis. Para entender se a variável “idade_frota” poderia afetar negativamente a previsão do HH, foram criados dois modelos para serem posteriormente comparados. No

primeiro modelo (Modelo_1), o campo “idade_frota” foi removido do conjunto de dados “X”, enquanto no segundo modelo (Modelo_2), o atributo “idade_frota” foi mantido no dataset. Para fins de comparação, ao final, serão extraídas métricas de ambos os modelos, garantindo assim a melhor precisão na previsão do HH.

Construção do modelo de rede neural sequencial

Foi utilizado um modelo sequencial da biblioteca *TensorFlow* para o desenvolvimento dos modelos a serem comparados. O Modelo_1 e o Modelo_2, são compostos por quatro camadas cada um.

No Modelo_1, a camada de entrada é composta por quatro neurônios, correspondendo a cada uma das variáveis independentes: acft, horas, ciclos e horas_mês. As segunda e terceira camadas são camadas ocultas, cada uma contendo 100 neurônios e utilizando a função de ativação ReLU. A quarta e última camada é a de saída, contendo um único neurônio, devido à previsão de apenas uma variável (HH); a função de ativação utilizada nessa camada é a linear. A Figura 5 apresenta um resumo do modelo, incluindo o total de parâmetros treinados.

Layer (type)	Output Shape	Param #
dense_9 (Dense)	(None, 100)	500
dense_10 (Dense)	(None, 100)	10,100
dense_11 (Dense)	(None, 1)	101

Total params: 10,701 (41.80 KB)
Trainable params: 10,701 (41.80 KB)
Non-trainable params: 0 (0.00 B)

Figura 5. Resumo do Modelo_1, extraído do *Python*
Fonte: Resultados originais da pesquisa

O Modelo_2 tem a mesma estrutura do Modelo_1, com exceção da camada de entrada, que passa a ter 5 neurônios, pois, no Modelo_2 é considerado a inclusão de mais uma variável independente, que se refere a idade da frota (acft, horas, ciclos, horas_mês, idade_frota), conforme a Figura 6.

Layer (type)	Output Shape	Param #
dense_3 (Dense)	(None, 100)	600
dense_4 (Dense)	(None, 100)	10,100
dense_5 (Dense)	(None, 1)	101

Total params: 10,801 (42.19 KB)

Trainable params: 10,801 (42.19 KB)

Non-trainable params: 0 (0.00 B)

Figura 6. Resumo do Modelo_2, extraído do *Python*
Fonte: Resultados originais da pesquisa

Comparando os resumos das Figuras 5 e a Figura 6, notou-se que, com o aumento das variáveis de entrada no Modelo_2, houve também um aumento de 100 parâmetros.

Posteriormente tanto o Modelo_1, quanto o Modelo_2, foram compilados usando o otimizador Adam e a função de perda MSE, que calcula o erro quadrático médio entre as previsões dos modelos e os valores reais, fornecendo uma medida quantitativa da qualidade das previsões.

Os modelos foram treinados por 10 épocas, em lotes (batch size) intervalados em 50 registros. Conforme as Figuras 7.

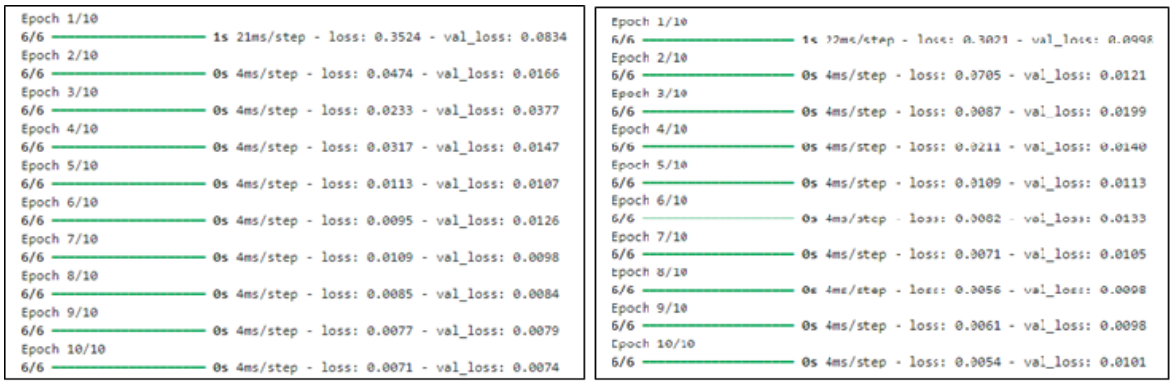
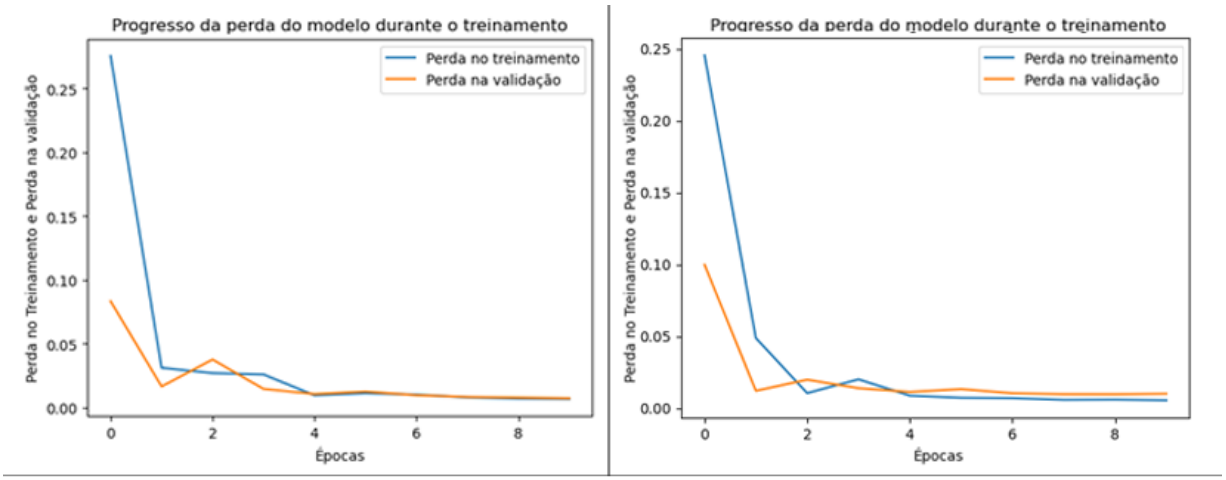


Figura 7. Épocas do Modelo_1 e Modelo_2, apresentando a *loss* e o *validation loss*
Fonte: Resultados originais da pesquisa

Para uma melhor visualização do treinamento e comparação entre o erro na base de dados de treinamento (loss) e o erro na base de dados de validação (validation loss). Confeccionados os gráficos para comparação dos dois modelos, como apresentado na Figura 8.



Modelo_1 Modelo_2

Figura 8. Comparação gráfica entre o Modelo_1 e o Modelo_2, apresentando a *training loss* e o *validation loss*
Fonte: Resultados originais da pesquisa

Observa-se que conforme o maior o número de épocas, "menor são o erro na base de dados de treinamento e o erro na base de dados de validação, tanto para o Modelo_1 quanto para o Modelo_2. Porém, no Modelo_1, o erro na base de validação fica mais próximo da base de treinamento, além de atingir um valor menor.

Por fim, para avaliação e comparação dos modelos, utilizou-se as seguintes métricas: RMSE, MSE, R^2 e R^2 ajustado, no Modelo_1, foram atingidos os seguintes resultados, conforme apresentados na Tabela 3.

Tabela 3. Métricas extraídas do Modelo_1

Métrica	Resultado
RMSE	119,540
MSE	14290,980
R^2	0,792
R^2 Ajustado	0,786

Fonte: Resultados originais da pesquisa

No Modelo_2, obteve-se os resultados descritos na Tabela 4.

Tabela 4. Métricas extraídas do Modelo_2

Métrica	Resultado
RMSE	130,697
MSE	17081,658
R^2	0,731
R^2 Ajustado	0,719

Fonte: Resultados originais da pesquisa

Comparando a Tabela 3 (Métricas do Modelo_1) com a Tabela 4 (Métricas do Modelo_2), foi observado que o Modelo_1 apresenta RMSE e MSE mais baixos, além de valores de R^2 e R^2 Ajustado mais próximos de 1 em comparação com o Modelo_2. Esses resultados indicam que o Modelo_1 é mais eficiente na previsão do [HH] para itens de manutenção não programada.

Ao representar graficamente os valores observados, em relação às previsões do modelo por meio de um gráfico de dispersão, verificou-se uma notável concordância entre os dados no Modelo_1, como ilustrado na Figura 9.

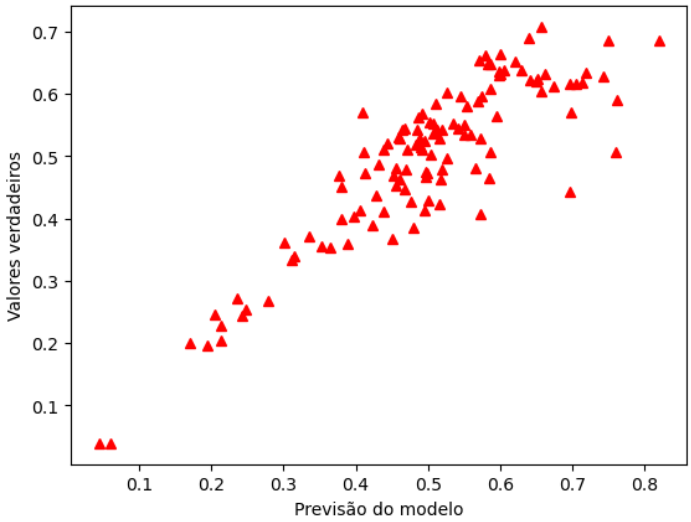


Figura 9. Gráfico de dispersão com valores verdadeiros vs valores previstos no modelo
Fonte: Resultados originais da pesquisa

Com o objetivo de apresentar os resultados no ambiente corporativo para clientes internos e externos de maneira clara, foi criado um gráfico de linhas comparando os valores reais de HH com as previsões do modelo. As previsões, representadas pela linha cinza, acompanharam de perto os valores reais, indicados pela linha preta. Isso reforça a eficácia do modelo e sua conformidade com as expectativas.

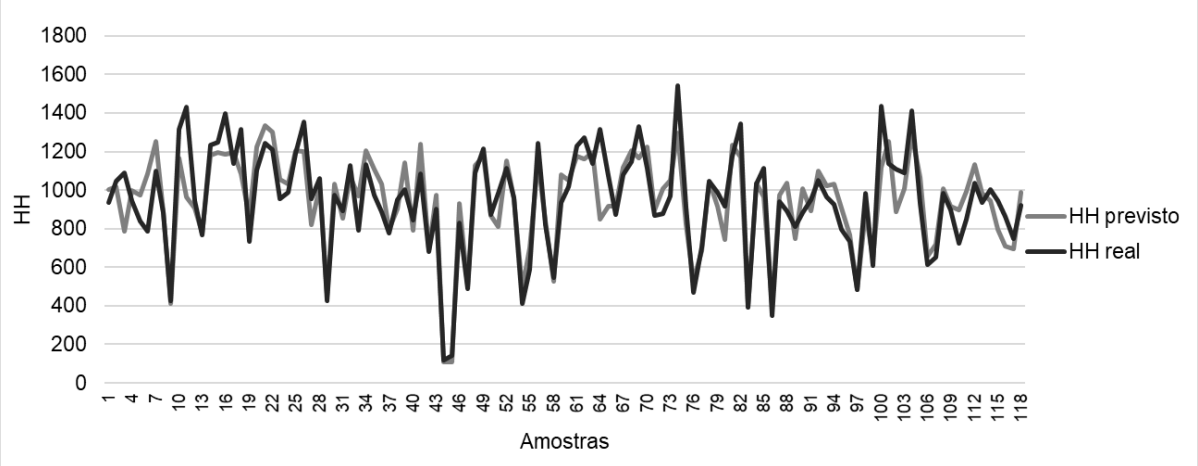


Figura 10. Gráfico de linha comparando HH previsto com o HH real.
Fonte: Resultados originais da pesquisa

Considerações Finais

O planejamento de manutenção é um pilar crucial para a operação eficiente de indústrias em diversos setores, incluindo a aviação. A gestão adequada de recursos humanos, especialmente na indústria da aviação, é vital para garantir a segurança e a eficiência das operações de manutenção, sejam elas programadas ou não.

Este estudo propôs uma abordagem inovadora utilizando Redes Neurais Artificiais (RNAs) para prever as Horas-Homem (HH) necessárias para manutenções não programadas em uma frota de Boeing 737NG de uma companhia aérea brasileira. A utilização de RNAs mostrou-se promissora na previsão de demandas imprevisíveis, como manutenções não programadas, melhorando a eficiência da alocação de recursos humanos.

A coleta, ajuste e integração dos dados foram etapas fundamentais para garantir a qualidade e a confiabilidade das previsões. A normalização dos dados foi essencial para tornar as variáveis comparáveis e melhorar a performance do modelo de RNA.

Os modelos desenvolvidos foram treinados e avaliados utilizando métricas relevantes como RMSE, MSE, R^2 e R^2 ajustado. O Modelo_1, que excluiu a variável "idade_frota", mostrou-se mais preciso em suas previsões em comparação com o Modelo_2, que incluiu essa variável.

Em resumo, este estudo demonstrou que a aplicação de RNAs para previsão de HH em manutenções não programadas pode ser uma ferramenta valiosa para companhias aéreas, auxiliando na otimização da gestão de recursos humanos e redução de custos operacionais. Contudo, é importante ressaltar que a implementação bem-sucedida deste modelo requer um processo contínuo de validação e ajuste, considerando a dinâmica e as particularidades de cada companhia aérea.

O avanço tecnológico e a crescente disponibilidade de dados tornam ainda mais relevante o desenvolvimento e aplicação de modelos de Machine Learning na indústria da aviação, contribuindo para operações mais seguras, eficientes e sustentáveis.

Agradecimento

Gostaria de expressar minha gratidão a todos que contribuíram para a realização deste trabalho. Agradeço primeiramente a Deus por me proporcionar sabedoria e resiliência no

decorrer do curso. Por fim, dedico este trabalho à minha família e à minha noiva, pelo constante apoio, amor e incentivo.

Referências

Li Yang, Yu Zhao, Xiaobing Ma, Group maintenance scheduling for two-component systems with failure interaction, Applied Mathematical Modelling, Volume 71, 2019, Pages 118-137, ISSN 0307-904X, https://doi.org/10.1016/j.apm.2019.01.036.

Syed Shaukat, Mathias Katscher, Cheng-Lung Wu, Felipe Delgado, Homero Larrain, Aircraft line maintenance scheduling and optimisation, Journal of Air Transport Management, Volume 89, 2020, 101914, ISSN 0969-6997, https://doi.org/10.1016/j.jairtraman.2020.101914.

Salah Albakkoush, Emanuele Pagone, Konstantinos Salonitis,An approach to airline MRO operators planning and scheduling during aircraft line maintenance checks using discrete event simulation, Procedia Manufacturing, Volume 54, 2021, Pages 160-165,ISSN 2351-9789, https://doi.org/10.1016/j.promfg.2021.07.024.

Smith, J. A., & Johnson, L. P. (2018). "Capacity planning and management: A strategic approach". Journal of Operations Management, 36(4), 432-446.

Data Wrangling for Big Data: Challenges and Opportunities, Tim Furche, Georg Gottlob, Leonid Libkin, Giorgio Orsi, Norman W. Paton.

Nicole Roberts, Michael Smith, Jingyi Qi, Data engineering for predictive machine learning of stormwater infrastructure conditions, Engineering Applications of Artificial Intelligence, Volume 133, Part C,2024,108195, ISSN 0952-1976, https://doi.org/10.1016/j.engappai.2024.108195.

Xinzhe Zhu, Yinan Li, Xiaonan Wang, Machine learning prediction of biochar yield and carbon contents in biochar based on biomass characteristics and pyrolysis conditions, Bioresource Technology, Volume 288, 2019, 121527, ISSN 0960-8524, https://doi.org/10.1016/j.biortech.2019.121527.

Yu Zhong, Fahang Liu, Guozhe Huang, Juan Zhang, Changhai Li, Yanming Ding,

Thermogravimetric experiments based prediction of biomass pyrolysis behavior: A comparison of typical machine learning regression models in Scikit-learn, Marine Pollution Bulletin, Volume 202, 2024, 116361, ISSN 0025-326X, https://doi.org/10.1016/j.marpolbul.2024.116361.

BARRETO, J. M. Introdução às redes neurais artificiais. Florianópolis: UFSC, 2002.

Luciano Ferreira, Gilnei Luiz de Moura, Denis Borenstein, Adalberto Américo Fischmann, Utilização de Redes Neurais Artificiais como Estratégia de Previsão de Preços no Contexto de Agronegócio, RAI Revista de Administração e Inovação, Volume 8, Issue 4, 2011, Pages 6-26, ISSN 1809-2039, https://doi.org/10.5773/rai.v8i4.475.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.

Nair, V., & Hinton, G. E. (2010). Rectified Linear Units Improve Restricted Boltzmann Machines. Proceedings of the 27th International Conference on International Conference on Machine Learning.

João Vitor Regis Falcão, Vinícius de Ávila Moreira, Celso de Ávila Ramos, Flávia Aparecida de Oliveira Santos, Universidade José do Rosário Vellano. REDES NEURAIS DEEP LEARNING COM TENSORFLOW, RE3C - Revista Eletrônica Científica de Ciência da Computação, v. 14 n. 1 (2019). (https://revistas.unifenas.br/index.php/RE3C/article/view/232)

Tom Eelbode, Pieter Sinonquel, Frederik Maes, Raf Bisschops, Pitfalls in training and validation of deep learning systems, Best Practice & Research Clinical Gastroenterology, Volumes 52–53, 2021, 101712, ISSN 1521-6918, https://doi.org/10.1016/j.bpg.2020.101712.

Kingma, D. P. and Ba, J. (2017). Adam: A method for stochastic optimization.

Hyndman, R. J., & Athanasopoulos, G. (2018). Forecasting: principles and practice. OTexts.

Bishop, C. M. (1995). Neural networks for pattern recognition. Oxford University Press.

Willmott, C. J. (1982). Some comments on the evaluation of model performance. Bulletin of the American Meteorological Society, 63(11), 1309-1313.

Pena, E. A., & Slate, E. H. (2006). Global validation of linear model assumptions. Journal of the American Statistical Association, 101(473), 341-354.

Sultonov Sarvar Mahammadodilovich. (2023). IMPORTANCE OF PYTHON PROGRAMMING LANGUAGE IN MACHINE LEARNING. INTERNATIONAL BULLETIN OF ENGINEERING AND TECHNOLOGY, 3(9), 28–30. https://doi.org/10.5281/zenodo.8374719.

Venkatesh Bhandage, Mallikharjuna Rao K, Satish Muppidi, Balajee Maram, Autism spectrum disorder classification using Adam war strategy optimization enabled deep belief network, Biomedical Signal Processing and Control, Volume 86, Part A, 2023, 104914, ISSN 1746-8094, https://doi.org/10.1016/j.bspc.2023.104914.